

Taller de Programación

TRABAJO PRÁCTICO N° 2

MÉTODOS NO SUPERVISADOS USANDO LA EPH

Fecha de entrega: viernes 24 de julio a las 13:00 h.

Contenido: Continuar con la familiarización con la base de datos de la Encuesta Permanente de Hogares. Practicar los métodos no supervisados vistos en clase (PCA & Clúster).

Modalidad de entrega

- Crear en el repositorio público de GitHub una carpeta llamada **TP2** con el código utilizado para resolver el trabajo práctico, indicando claramente a qué inciso corresponde cada parte.
- Incluir en esa carpeta el informe final en PDF, con gráficos e imágenes integrados, nombrado **TP2_Programacion_Grupo#.pdf** (# corresponde al número de grupo). El informe no debe superar las 5 páginas, sin contar apéndices.
- Subir al campus virtual únicamente el informe, en *Trabajos Prácticos* > *Entrega Informe 2*. La primera página debe contener el link al repositorio de GitHub.
- Antes de entregar, realizar el *commit* y *push* finales con el mensaje “Entrega final del TP”. La versión evaluada será la última disponible en GitHub al momento de la entrega; no realizar nuevos cambios después.
- **Cualquier detección de copia o plagio será sancionada.**

Parte I: Creación de variables y más estadística descriptiva

La idea de esta primera parte es que completen la limpieza de la base de datos que contiene las observaciones del **cuarto** trimestre de **2024** y **2025**. Para todos los gráficos, recuerde mantener los principios de visualización de la clase 1 y feedback de Noelia a su TP1.

1) Creación de variables:

- a) Cree la variable “*edad2*” definida como edad^2 (edad al cuadrado).
- b) También, cree la variable *educ* definida como la cantidad de años de educación. Use inteligentemente las variables CH12, CH13 y CH14

para crearla. Por ejemplo, si dice que el nivel más alto de educación es “Secundario” (CH12), “Sí” finalizó este nivel (CH13) y el último año que aprobó (CH14) fue “sexto”, entonces puede asumir que tiene $educ=12$, ósea 12 años de educación formal.

- c) Para el jefe del hogar, cree la variable *horastrab* como el total de horas trabajadas como la suma de las horas en la ocupación principal y otras ocupaciones (PP3E_TOT + PP3F_TOT).
 - d) Cree una variable *nhogar* con el número de miembros por el hogar (*Hint*: use inteligentemente CODUSO, N_HOGAR y COMPONENTE).
- 2) Estadística descriptiva: Presente una estadística descriptiva (observaciones, promedio, sd, min, p25, p50, p75, max) de todas las variables limpias en el TP1 y estas nuevas variables numéricas creadas. Comente brevemente la tabla.
- 3) Con la base de ocupados creada en el TP1, realice una matriz de correlaciones para 2024 y 2025, respectivamente; con las variables *informal* (con la definición que le fue asignada en el TP1), *edad*, *edad2*, *educ*, *horastrabj*, *nhogar*, P21, PP04C; y comente dicha matriz. Para esta muestra con dichos predictores ¿es un contexto de alta, mediana, o baja correlación parcial entre los predictores mencionados e informalidad? ¿Se observa un cambio significativos de los coeficientes de correlacion parcial entre 2024 y 2025?

Parte II: Métodos No Supervisados

A. PCA

1. PCA: Apliquen PCA a las variables: *edad*, *edad2*, *educ*, *horastrabj*, *nhogar*, P21, y PP04C de la base de ocupados. En un gráfico de dispersión muestren los índices (*scores*) calculados del primer y segundo componente de PCA y comente los resultados. En dicho grafico, utilice un color para las observaciones que son formales y otro para formales. ¿Nota algún patrón de los scores e informalidad laboral? ¿Encuentran algunos outliers?
2. Grafique con flechas los ponderadores (*loading*) de PCA para el primer y segundo componente; comente los pesos que le dan a cada variable utilizada. Utilice un color para los scores de individuos formales y otro para los informales (según la definición que le toco). ¿Hay algún patrón en todas las dimensiones entre los formales e informales en el espacio del primer y segundo compontente?
3. Finalmente, grafique la proporción de la varianza explicada para cada uno de los siete componentes y comente el gráfico en relación al contexto de correlaciones que observaron en el ítem 3 de la Parte I.

B. Clúster

4. Clúster k-medias:
 - a. Para la misma selección de variables de la parte II.A, corran el algoritmo con $k = 2$, usando $n_{init} = 20$, y grafiquen los resultados usando dos variables de las siete seleccionadas. Interpretenlos ¿Puede el algoritmo con $k = 2$ separar correctamente a las personas informales y formales?
 - b. Grafique alguna medida de disimilitud para $k = 1$ hasta $k = 40$. Usando la inspección visual de *Elbow* ¿cuál sería el número óptimo de clusters?
5. Clúster jerárquico: Utilizando las variables mencionadas arriba, realicen un análisis de clustering jerárquico. Generen un dendograma, expliquen brevemente qué es un dendograma y qué resultados obtuvieron.
6. Clúster k-moda:
 - a. Implemente clúster k-moda con $k = 2$ para todas las variables **dummies** de la EPH que creo inteligentemente en el TP1 y las nuevas variables numericas de este TP pero categorizadas. Use como input todas estas características sin la variable **objetivo informales** (que se utilizara más adelante en clasificación) ¿Puede el algoritmo k-modas con $k = 2$ separar correctamente a las personas informales y formales en su definición?
 - b. Encuentre el número de clúster óptimo según el método de Elbow para k-modas y comente diferencias con k-medias.

Parte III: Herramientas de IA y reflexión final.

A continuación, se solicita explicitar el uso de herramientas de Inteligencia Artificial a lo largo del TP. Con el fin de promover un uso transparente, crítico y reflexivo de estas tecnologías, se deberá documentar lo realizado con las mismas y evaluar su aporte en este trabajo práctico.

1. Reflexión (máximo 1 párrafo): Comenten cómo les ayudó la IA a programar: ¿en qué ítems fue más útil y en cuáles les resultó más difícil o menos efectiva? ¿Los ayudó en la interpretación?
2. Incluyan un Apéndice con todos los prompts de IA utilizados a lo largo del TP, copiados textualmente y en el orden en que fueron usados, y el nombre de la LLM utilizado (ChatGPT, Claude, Gemini, etc.) .
3. Por último, reporten aproximadamente el **tiempo total (en horas)** dedicado a la realización de este trabajo práctico.