

Universidad de Buenos Aires

Facultad de Ciencias Económicas

Escuela de Negocios y Administración Pública

---

**MAESTRÍA EN ECONOMÍA APLICADA**

---

TALLER DE PROGRAMACIÓN

---

Segundo trabajo práctico – Grupo 3

---

INTEGRANTES:

LUCIANO ALTAMIRANO

GONZALO PASICHE

GITHUB:

[HTTPS://GITHUB.COM/LUCIANOALTAMIRANO435-RGB/GRUPO\\_3\\_TRABAJOS\\_PRACTICOS.GIT](https://github.com/LUCIANOALTAMIRANO435-RGB/GRUPO_3_TRABAJOS_PRACTICOS.GIT)

PROFESORA:

MARÍA NOELIA ROMERO

JULIO - 2026

1. Análisis descriptivo de las variables

Este aborda los ocupados de los cuartos trimestres de 2024 y 2025, a partir de un conjunto de variables continuas elaboradas a partir de los datos de la Encuesta Permanente de Hogares (EPH). Para ello, en primer lugar, se presentan varios estadísticos descriptivos (media, desvío típico, mínimo, percentiles y máximo) de las variables de interés analítico, tanto las del TP1 como las nuevas variables construidas. En segundo lugar, se consideran las correlaciones entre variables a partir de dos *heatmaps* de los coeficientes de Pearson para cada año de análisis, con el fin de describir el contexto de las correlaciones parciales entre las variables predictoras.

Tabla 1

Estadísticos descriptivos de las variables de interés analítico

| Variables                           | Observaciones | Promedio   | Desvío Estándar | Min    | P25        | P50        | P75          | Max           |
|-------------------------------------|---------------|------------|-----------------|--------|------------|------------|--------------|---------------|
| Edad                                | 40.830        | 41,57      | 13,21           | 11,00  | 31,00      | 41,00      | 51,00        | 100,00        |
| Ingreso ocupación principal         | 32.641        | 768.768,90 | 784.208,65      | 0,00   | 300.000,00 | 600.000,00 | 1.000.000,00 | 30.000.000,00 |
| Ingreso total individual            | 31.850        | 872.329,63 | 866.382,28      | 0,00   | 400.000,00 | 700.000,00 | 1.025.000,00 | 30.000.000,00 |
| Cantidad de ocupaciones adicionales | 40.824        | 0,23       | 0,72            | 0,00   | 0,00       | 0,00       | 0,00         | 8,00          |
| Tamaño del establecimiento (codigo) | 35.427        | 4,90       | 3,79            | 0,00   | 1,00       | 4,00       | 8,00         | 12,00         |
| Edad al cuadrado                    | 40.830        | 1.902,79   | 1.166,71        | 121,00 | 961,00     | 1.681,00   | 2.601,00     | 10.000,00     |
| Años de educacion                   | 40.326        | 12,00      | 3,63            | 0,00   | 10,00      | 12,00      | 15,00        | 22,00         |
| Horas trabajadas (jefe/a)           | 19.962        | 38,94      | 17,01           | 0,00   | 30,00      | 40,00      | 48,00        | 184,00        |
| Horas trabajadas del jefe/a (hogar) | 33.433        | 39,07      | 17,11           | 0,00   | 30,00      | 40,00      | 48,00        | 184,00        |
| Miembros del hogar                  | 40.830        | 3,59       | 1,81            | 1,00   | 2,00       | 3,00       | 4,00         | 19,00         |


Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del Instituto Nacional de Estadística y Censos (INDEC, 2026).

La base de las ocupaciones es de 40830 observaciones, con una edad promedio de 41,57 años, una desviación de 13,21 años y un rango de 11 a 100 años, lo que muestra un grupo de ocupados adultos disperso en cuanto a su edad. El promedio de la educación alcanza los 12,00 años, con una desviación de 3,63, y el percentil 25 de 10 años nos indica que un grupo importante de los ocupados no alcanzó el secundario. El promedio de miembros del hogar se sitúa en 3,59, con un máximo de 19, y el percentil 75 se ubica en 4, lo que indica que la gran mayoría de los hogares son medianos, aunque no faltan los de alta densidad. Las horas trabajadas por el jefe o jefa del hogar promedian 39,07, con una desviación de 17,11, y el percentil 25, que se sitúa en 30, sugiere una base no despreciable de subocupación entre los jefes de hogar.

La razón por la que da lugar a un salario de 768.768,90 pesos y su desvío de 784.208,65 se acercan muchísimo a la media, de hecho, anticipa una distribución fuertemente sesgada a la derecha, ya que aparece un máximo de 30.000.000,00. En efecto, el percentil 50 corresponde a 600.000,00 y el percentil 75 a 1.000.000,00, lo que confirma que la mitad de los ocupados tiene ingresos inferiores a la media, un patrón que se replica en el correspondiente a los ingresos totales individuales, donde la media de 872.329,63 pesos supera en aproximadamente 103.000,00 pesos a la de ocupación principal, diferencia esta que se explica por los ingresos de la ocupación secundaria y de las fuentes de ingresos no laborales. El tamaño del establecimiento registra una media de 4,90; la mediana es 4,00 y el percentil 75 corresponde a 8,00.

Figura 1

Coeficientes de correlación de Pearson de las variables de análisis



Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026). En las tablas 1.1 y 1.2 de los anexos se detallan los coeficientes de correlación de Pearson y sus valores p correspondientes.


La correlación entre la edad y la edad al cuadrado es de 0,99 en 2024 y de 0,98 en 2025, lo que refleja la colinealidad esperada entre ellas, dado que ambas están construidas a partir de la misma variable. Los predictores muestran correlaciones bajas con la informalidad: así, el tamaño del establecimiento presenta la correlación negativa más fuerte, con valores de 0,35 y 0,33, respectivamente, seguido por el ingreso de la ocupación principal, con 0,25 y 0,22, y los años de educación, con 0,20 y 0,19. La informalidad se asocia más con un tamaño pequeño de los establecimientos, ingresos bajos y una menor acumulación de capital humano. Los predictores entre sí muestran una correlación moderada, puesto que el ingreso y el tamaño del establecimiento presentan valores de alrededor de 0,38 y 0,31, respectivamente, y los coeficientes son en gran medida estables entre ambos años, sin grandes cambios en los pares de variables analizadas.

2. Análisis de Componentes Principales (PCA) de las características del mercado laboral

El presente apartado implementa el análisis de componentes principales sobre las variables edad, edad al cuadrado, años de escolaridad, horas trabajadas del jefe o de la jefa de familia, miembros de la unidad familiar (hogar), ingreso de la ocupación principal y tamaño del establecimiento, para la muestra conjunta de ocupados de los cuartos trimestres de 2024 y 2025. Se analizan los scores del primer y del segundo componente diferenciando trabajadores formales e informales, se revisan los *loadings* de cada variable en el plano bidimensional y se da a conocer la proporción de varianza explicada por cada componente, ligándola a la que caracteriza el contexto de correlaciones de la que da cuenta la sección anterior.

Figura 2

Scores de los dos primeros componentes principales y bitplot de scores y loadings de los ocupados formales e informales



Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

El panel de la parte izquierda muestra que los scores del primer componente, que explica el 29,6% de la varianza, se extienden principalmente a valores positivos, con una distribución asimétrica, mientras que el segundo componente, con un 24,6%, presenta una dispersión relativamente más simétrica respecto de cero. Los ocupados informales se distribuyen fundamentalmente en el área de scores negativos del primer componente y en torno a un valor ligeramente por debajo de cero en el segundo, aunque su solapamiento con los formales es importante. Por otro lado, se observa la presencia de outliers en valores extremos positivos de ambos componentes, asociados a ocupados con perfiles atípicos de ingreso o de edad, todos ellos formales.


En el biplot, la edad, así como el cuadrado de la edad, predominan en el primer cuadrante positivo del primer componente; se trata de flechas casi horizontales de gran longitud, lo que indica que el primer componente recoge en gran medida la dimensión de la edad. En el primer cuadrante positivo del segundo componente se observa que el ingreso de la ocupación principal es la flecha con mayor longitud, seguida del tamaño de establecimiento y de los años de educación, lo que sugiere que el segundo componente expresa una dimensión de calidad e inserción laboral. En el segundo cuadrante negativo del segundo componente, los miembros del

hogar apuntan en sentido contrario al ingreso, de tal forma que los hogares más numerosos están asociados a peores condiciones de inserción laboral, patrón que también está en sintonía con una mayor presencia de puntos rojos en esta zona.

Una gran parte de la población ocupada con relación a la informalidad se encuentra notablemente concentrada en la parte baja (en el tercer cuadrante) del espacio bidimensional antes mencionado, es decir, en una población ocupada con scores negativos en ambos componentes principales. Este esquema resulta coherente con la definición de informalidad adoptada, dado que hace corresponder la no percepción del descuento jubilatorio al trabajo en pequeños establecimientos, esto es, a las características típicas y asociadas a remuneraciones bajas, a un menor capital educativo acumulado y a hogares con mayor número de cargas familiares. Sin embargo, la gran cantidad de observaciones de ocupados formales indica que la vulnerabilidad socioeconómica trasciende la mera informalidad, tal como la conciben Maurizio y Monsalvo (2021), por lo que es posible que esta no abstraiga adecuadamente la caracterización del mercado laboral entre formales e informales, dada la realidad actual de Argentina.

**Figura 3**

*Proporción de la varianza explicada en los ocupados*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

El primer componente representa el 29,6% de la varianza, el segundo explica el 24,6%, lo que da un total del 54,2%, una cifra moderada que concuerda con el nivel de correlaciones bajas ya argumentado en la Parte I. Así la varianza está relativamente repartida entre los siete componentes, el tercero y el cuarto explican en torno al 14,5% y 12,6% respectivamente, y los componentes quinto y sexto explican el 9,4% y el 9,1%. Antes del séptimo componente, la varianza acumulada es del 99,8% y este no explica casi nada, con un 0,2%. La ausencia de un componente dominante concuerda con la falta de correlaciones elevadas entre los predictores, lo que implica que no existe un componente que resuma adecuadamente la heterogeneidad de las condiciones de inserción laboral de los ocupados.

### 3. Análisis clúster de la informalidad del mercado laboral

#### 3.1. Análisis clúster k-medias

##### 3.1.1. Clúster k-medias con $k = 2$

Antes de la aplicación del método, se estandarizaron las siete variables utilizadas, ya que k-medias trabaja con distancias euclídeas y por ello, variables como el ingreso, medido en cientos de miles de pesos, habrían tomado mayor relevancia en comparación con otras variables como la cantidad de miembros del hogar. Además, el  $n_{init}$  fijado fue de 20, lo que permite un número adecuado de iteraciones.

Para evaluar si los grupos obtenidos reproducen la informalidad, se utiliza la pureza, que es el porcentaje de casos correctamente ubicados cuando a cada clúster se le asigna la categoría más frecuente entre sus miembros. Ese número es importante al compararlo

con la línea de base, es decir, con el porcentaje que arrojaría si se clasificara toda la muestra como formal. En el caso presentado, ambos valores coinciden en 84,2%, de modo que la ganancia es nula y, por ende, el agrupamiento por k-medias con  $k = 2$  no separa, como se esperaba, entre formales e informales.

El **Anexo 3.1** muestra con bastante claridad las razones de esta afirmación. En el panel izquierdo se ve que el algoritmo trazó su frontera alrededor de los 48 años, con una leve inclinación hacia el ingreso, y lo que dividió fue esencialmente entre trabajadores jóvenes y de ingresos bajos, por un lado, y trabajadores mayores, por el otro. Mientras que, en el panel derecho, los informales no forman ninguna región propia: aparecen a lo largo de todo el rango etario y se apilan en la franja inferior de ingresos, pero mezclados con los formales que ganan lo mismo. Por ello, la informalidad, tal como fue construida, depende de no tener descuento jubilatorio en un establecimiento pequeño, y esa condición no tiene por qué alinearse con ningún eje de variación de las siete variables que usamos.

### **3.1.2. Método del codo**

La inercia siempre disminuye al agregar clústeres, así que lo buscado no es el mínimo, sino el punto en el que deja de mejorar apreciablemente. Como se observa en el **Anexo 3.2**, cae 20,3% al pasar de uno a dos grupos y 15% al pasar de dos a tres, pero desde  $k = 4$  la mejora ya está por debajo del 8% y, de ahí en adelante, desciende de forma pareja, sin quiebres. Por ello, el número adecuado podría situarse entre  $k = 3$  y  $k = 5$ .

### **3.2. Clúster jerárquico**

El dendrograma es la representación de un procedimiento aglomerativo: se arranca con cada observación como grupo propio y, en cada paso, se fusionan los dos más parecidos hasta obtener un único grupo. La altura de cada unión indica la disimilitud a la que se produjo esa fusión, por lo que cortar el árbol horizontalmente equivale a quedarse con un número determinado de clústeres. Usamos el método de Ward, que fusiona minimizando el aumento de la varianza interna, y trabajamos con una muestra aleatoria de 300 casos, ya que el método exige calcular la distancia entre todos los pares de observaciones y, con la base completa, esto haría que ascendiera a más de mil millones de distancias, lo cual implicaría un gran esfuerzo computacional y un gráfico difícil de interpretar.

En el **Anexo 3.3** se observa que la última fusión ocurre cerca de 29 y separa dos ramas de tamaños desiguales: una con aproximadamente un cuarto de los casos y la otra con el resto. El salto entre esa unión y la anterior, ubicada en torno a 22, es el mayor de todo el árbol y sería el argumento a favor de quedarse con dos grupos.

### **3.3. Clúster k-modas**

#### **3.3.1. Clúster k-modas con $k = 2$**

K-modas es la versión del algoritmo para datos categóricos: usa la moda en lugar de la media como representante de cada grupo y mide la distancia contando cuántos atributos difieren entre dos observaciones. Para este trabajo se tomaron dos decisiones metodológicas. La primera fue que todas las variables ingresaran como categóricas, cada una en una sola columna con sus etiquetas originales, sin expandirlas en columnas binarias cuando tenían más de dos categorías; de haberlo hecho, cada nivel habría contado como una variable independiente y las de muchas categorías, como los tramos de educación o de ingreso, habrían quedado sobrerrepresentadas en la distancia. Cabe aclarar que, para las dicotómicas construidas en el TP1, la codificación es indistinta, dado que la métrica sólo evalúa si dos valores coinciden. La segunda decisión fue tratar los faltantes como una categoría adicional en lugar de eliminarlos, ya que el algoritmo no admite datos ausentes y descartarlos implicaría perder cerca de un tercio de la muestra; además, la no respuesta es informativa en sí misma, sobre todo en ingresos, donde se asocia a perfiles laborales bastante particulares. El input quedó conformado por las dicotómicas del TP1, más las nuevas variables numéricas categorizadas, sin la variable objetivo.

El resultado es muy similar a lo visto en la sección de k-medias. En el panel izquierdo del **Anexo 3.4** se observa que un clúster concentra el 12,5% de informales y el otro, el 17,1%, una diferencia de apenas 4,6 pp sobre una tasa general cercana al 15%. La

pureza llega al 84,9% y la línea de base es idéntica, así que otra vez la ganancia es nula, algo que el panel derecho del mismo gráfico muestra de manera directa al poner ambas barras a la misma altura para los dos métodos.

Así, la lectura es que, al trabajar con trece atributos categóricos, el algoritmo agrupa según los rasgos que más dividen a la población ocupada en general, y esos rasgos no son los que definen la informalidad. A eso se suma que los informales son una minoría, mientras que tanto k-medias como k-modas tienden a formar grupos de tamaño similar, por lo que difícilmente pueden aislar un subconjunto pequeño.

### 3.3.2. Método del codo para k-modas

La medida de disimilitud acá es el costo, que suma los atributos que separan cada observación de la moda de su clúster. Cumple el mismo rol que la inercia, pero se mide en desacuerdos y no en distancias al cuadrado, por lo que, para compararlas, es necesario normalizar ambas curvas a un valor de  $k = 1$ . Corrimos este ítem sobre una muestra de 5.000 casos y con  $n_{init} = 5$ , ya que k-modas es mucho más lento que k-medias y cuarenta valores de k sobre la base completa implicarían un costo computacional altísimo.

El **Anexo 3.5** muestra la curva de costo y el **Anexo 3.6** la compara con la de k-medias. De ello se derivan 3 diferencias en la comparación. La caída del costo es bastante menor: en  $k = 40$  todavía conserva el 52% de su valor inicial, mientras que la inercia baja al 26%, como se aprecia en el panel izquierdo del **Gráfico 3.6**. Esto se debe a que la distancia de Hamming está acotada por el número de variables, mientras que la euclídea no tiene techo y los valores extremos empujan la inercia hacia arriba. La curva de k-modas tampoco es suave: en el panel derecho se observan reducciones marginales negativas en  $k = 6$  y  $k = 13$ , lo cual se explica por la convergencia a óptimos locales y por el acento que el  $n_{init}$  reducido acentúa. Y el codo resulta aún más difuso, porque la mejora marginal cae por debajo del 3% ya en  $k = 3$  y de ahí oscila sin una tendencia clara.

De esta forma, ambos métodos coinciden en ubicar el número óptimo entre tres y cinco clústeres, y en ningún caso  $k = 2$  aparece como la cantidad natural de grupos. Esto genera una conclusión bastante consistente de lo que se ha hecho: si la estructura de los datos no sugiere dos grupos, difícilmente el algoritmo será capaz de recuperar una partición binaria como la de formales e informales.

## 4. Herramientas de la IA y reflexión final

### 4.1. Reflexiones finales

Por una parte, se valora la contribución de la inteligencia artificial como herramienta de aprendizaje y programación, remarcando su utilidad para acceder rápidamente a la base de datos y, al mismo tiempo, para generar código que se interprete con claridad en Python, aunque se considera que el apoyo fue menos relevante en la fase interpretativa. A continuación, un registro de *prompts* que se van utilizando a lo largo del desarrollo y que se refiere a un apéndice. Finalmente, se valora el tiempo total dedicado a este trabajo, teniendo en cuenta las dificultades de entrega, que se asocian principalmente a un aprendizaje lento al adaptarse a nuevas herramientas de trabajo colaborativo y a conceptos que anteriormente no se habían visto.

### 4.2. Prompts usados (Apéndice 1)

### 4.3. Tiempo estimado

Pese a la utilidad que representa la IA, al tratarse del primer trabajo práctico, el proceso ha demandado un tiempo considerable, principalmente debido a la adaptación al uso de GitHub, al aprendizaje de su funcionamiento y a los otros costos de transacción propios del trabajo virtual, que, afortunadamente, han disminuido. Además, ha permitido la adecuación a nuevos conceptos, como los clústeres jerárquicos y las k-modas, que resultaron retadores. En conjunto, esto ha supuesto una dedicación de aproximadamente 15 horas. Se espera que este tiempo se reduzca en los próximos entregables, considerando además el escaso margen temporal entre ellos según el cronograma y la existencia de otras responsabilidades que deben atenderse en paralelo.

5. Referencias

Instituto Nacional de Estadística y Censos. (2026). *Bases de datos*. <https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos>

Maurizio, R., y Monsalvo, A. P. (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America* (Vol. 2021). United Nations. <https://doi.org/10.35188/UNU-WIDER/2021/953-2>

1. Anexos y apéndices

Tabla 1.1

Matriz de correlación entre las variables de interés del año 2024

| Variables                   | Informalidad | Edad  | Edad al cuadrado | Años de educación | Horas trabajadas (jefe) | Miembros del hogar | Ingreso ocupación principal | Tamaño del establecimiento |
|-----------------------------|--------------|-------|------------------|-------------------|-------------------------|--------------------|-----------------------------|----------------------------|
| Correlación de Pearson      |              |       |                  |                   |                         |                    |                             |                            |
| Informalidad                | 1,00         | -0,13 | -0,12            | -0,20             | -0,08                   | 0,12               | -0,25                       | -0,35                      |
| Edad                        | -0,13        | 1,00  | 0,99             | -0,07             | -0,06                   | -0,17              | 0,12                        | -0,05                      |
| Edad al cuadrado            | -0,12        | 0,99  | 1,00             | -0,08             | -0,08                   | -0,18              | 0,10                        | -0,07                      |
| Años de educación           | -0,20        | -0,07 | -0,08            | 1,00              | 0,06                    | -0,20              | 0,30                        | 0,29                       |
| Horas trabajadas (jefe)     | -0,08        | -0,06 | -0,08            | 0,06              | 1,00                    | 0,01               | 0,20                        | 0,10                       |
| Miembros del hogar          | 0,12         | -0,17 | -0,18            | -0,20             | 0,01                    | 1,00               | -0,15                       | -0,08                      |
| Ingreso ocupación principal | -0,25        | 0,12  | 0,10             | 0,30              | 0,20                    | -0,15              | 1,00                        | 0,38                       |
| Tamaño del establecimiento  | -0,35        | -0,05 | -0,07            | 0,29              | 0,10                    | -0,08              | 0,38                        | 1,00                       |
| Valores p                   |              |       |                  |                   |                         |                    |                             |                            |
| Informalidad                | 1,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Edad                        | 0,00         | 1,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Edad al cuadrado            | 0,00         | 0,00  | 1,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Años de educación           | 0,00         | 0,00  | 0,00             | 1,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Horas trabajadas (jefe)     | 0,00         | 0,00  | 0,00             | 0,00              | 1,00                    | 0,38               | 0,00                        | 0,00                       |
| Miembros del hogar          | 0,00         | 0,00  | 0,00             | 0,00              | 0,38                    | 1,00               | 0,00                        | 0,00                       |
| Ingreso ocupación principal | 0,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 1,00                        | 0,00                       |
| Tamaño del establecimiento  | 0,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 1,00                       |

Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

Tabla 1.2


Matriz de correlación entre las variables de interés del año 2025

| Variables                   | Informalidad | Edad  | Edad al cuadrado | Años de educación | Horas trabajadas (jefe) | Miembros del hogar | Ingreso ocupación principal | Tamaño del establecimiento |
|-----------------------------|--------------|-------|------------------|-------------------|-------------------------|--------------------|-----------------------------|----------------------------|
| Correlación de Pearson      |              |       |                  |                   |                         |                    |                             |                            |
| Informalidad                | 1,00         | -0,13 | -0,11            | -0,19             | -0,10                   | 0,11               | -0,22                       | -0,33                      |
| Edad                        | -0,13        | 1,00  | 0,98             | -0,09             | -0,05                   | -0,18              | 0,12                        | -0,05                      |
| Edad al cuadrado            | -0,11        | 0,98  | 1,00             | -0,11             | -0,06                   | -0,18              | 0,09                        | -0,07                      |
| Años de educación           | -0,19        | -0,09 | -0,11            | 1,00              | 0,04                    | -0,20              | 0,29                        | 0,30                       |
| Horas trabajadas (jefe)     | -0,10        | -0,05 | -0,06            | 0,04              | 1,00                    | 0,00               | 0,14                        | 0,07                       |
| Miembros del hogar          | 0,11         | -0,18 | -0,18            | -0,20             | 0,00                    | 1,00               | -0,14                       | -0,08                      |
| Ingreso ocupación principal | -0,22        | 0,12  | 0,09             | 0,29              | 0,14                    | -0,14              | 1,00                        | 0,31                       |
| Tamaño del establecimiento  | -0,33        | -0,05 | -0,07            | 0,30              | 0,07                    | -0,08              | 0,31                        | 1,00                       |
| Valores p                   |              |       |                  |                   |                         |                    |                             |                            |
| Informalidad                | 1,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Edad                        | 0,00         | 1,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Edad al cuadrado            | 0,00         | 0,00  | 1,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Años de educación           | 0,00         | 0,00  | 0,00             | 1,00              | 0,00                    | 0,00               | 0,00                        | 0,00                       |
| Horas trabajadas (jefe)     | 0,00         | 0,00  | 0,00             | 0,00              | 1,00                    | 0,56               | 0,00                        | 0,00                       |
| Miembros del hogar          | 0,00         | 0,00  | 0,00             | 0,00              | 0,56                    | 1,00               | 0,00                        | 0,00                       |
| Ingreso ocupación principal | 0,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 1,00                        | 0,00                       |
| Tamaño del establecimiento  | 0,00         | 0,00  | 0,00             | 0,00              | 0,00                    | 0,00               | 0,00                        | 1,00                       |

Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

Gráfico 3.1


Clúster K=2 y su relación con el índice de informalidad laboral construido



Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

### Gráfico 3.2


*Método del (Elbow) y su aplicación en el K-medias*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

### Gráfico 3.3


*Dendrograma jerárquico*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

### Gráfico 3.4

*Composición del indicador de informalidad bajo agrupamiento de K-modas*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).



### Gráfico 3.5


*Método del (Elbow) y su aplicación en el K-modas*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

### Gráfico 3.6

*Comparación de las curvas de codo: K-medias y K-modas*



*Nota.* Elaboración propia con base en la Encuesta Permanente de Hogares del INDEC (2026).

## Apéndice 1: Prompts utilizados

- Continuaremos trabajando con la base trabajada en la anterior ocasión, la base se llama ocupados
- Mira las siguientes variables: estas variables las utilizaré para hacer un clúster, mi idea es comparar con el indicador de informalidad construido, para ello los pasos son los siguientes: usemos un  $k=2$  y  $n_{init}=20$ , el clúster solo elabóralo con las 7 variables mostradas, y sobre compararemos, con el indicador. La forma en que se comparara es: Coloquemos 2 gráficos de edad e ingreso de ocupación principal (tal como te mostré en la imagen), el primero agrupado con la clasificación del clúster y el segundo con la clasificación del índice de informalidad. Nota importante no te olvides de estandarizar las variables. Existe información adicional que necesitas para realizar la tarea encomendada?
- Construye el gráfico de codo sobre la base del clústeres con  $k=1$  hasta  $k=40$
- Explicame que es un dendograma, también es necesario estandarizar?
- De acuerdo, sobre las variables que aplicadas en el clúster  $k=2$  y el gráfico de codo, apliquemos el dendograma
- Entiendo que si el agrupamiento de 2 cluster es más alto, significa que el algoritmo recomienda un  $k=2$ , en este caso veo que sería entre 4 y 5 aprox (mira la imagen cargada), te parece que es correcta esa interpretación?
- En que se diferencia el dendograma como lo que venimos trabajando?
- Es correcto que usemos menos muestra que en K-medias?
- Existe ganancia adicional en usar mayor muestra?

- Perfecto, ahora pasemos al método de k-modas, la aplicación será a partir de variables categóricas y numéricas, entonces primero necesito identificar de forma clara todas las variables de la base, para ello te coloco los resultado del `ocupados.info()` pero además necesito que me pases un código más legible para ver todas las variables por categoría de formas más ordenada
- Perfecto, estos son los resultados, aquí podrás ver las variables y su respectivo tipo. Muchas de las variables son categóricas, es necesario que las que tienen más de 1 nivel se conviertan en dummy?
- Que es la distancia de Hamming?
- Perfecto entonces pasemos a la aplicación,
- Pasemos al método del codo, análogo a lo hecho en k-medias
- Podrías comparar los métodos de codo hecho en k medias y k modas, estos son los códigos aplicados