

Taller de Programación

TRABAJO PRÁCTICO N° 3

CLASIFICANDO DE INFORMALES EN LA EPH

Fecha de entrega: lunes 17 de agosto a las 13:00 hs.

Contenido: Introducción a los métodos de clasificación vistos en clase: regresión logística y vecinos cercanos. Métricas de desempeño y Curvas ROC.

Modalidad de entrega

- Crear en el repositorio público de GitHub una carpeta llamada **TP2** con el código utilizado para resolver el trabajo práctico, indicando claramente a qué inciso corresponde cada parte.
- Incluir en esa carpeta el informe final en PDF, con gráficos e imágenes integrados, nombrado **TP2_Programacion_Grupo#.pdf** (# corresponde al número de grupo). El informe no debe superar las 5 páginas, sin contar apéndices.
- Subir al campus virtual únicamente el informe, en *Trabajos Prácticos* > *Entrega Informe 2*. La primera página debe contener el link al repositorio de GitHub.
- Antes de entregar, realizar el *commit* y *push* finales con el mensaje “Entrega final del TP”. La versión evaluada será la última disponible en GitHub al momento de la entrega; no realizar nuevos cambios después.
- **Cualquier detección de copia o plagio será sancionada.**

A. Enfoque de validación: 2024 como entrenamiento, 2025 como testeo

El objetivo de este trabajo práctico es intentar predecir si una persona es informal o no utilizando la definición asignada desde el TP1 y las variables de creadas en el TP1 y TP2. Para realizar este trabajo, utilicen la base ocupados con las dummies creadas inteligentemente en el TP1 y las variables numéricas del TP2. Si no guardaron esa base como archivo, guárdenla antes de resolver las siguientes consignas.

Utilizando la base ocupados:

1. Separen la base ocupados en: `ocupados_X_2024`, está sera su base de entrenamiento (*train*), y `ocupados_X_2025`, está sera su base de testeo (*test*); cada una solo con las variables de características X.¹ Luego, separe en vectores columnas `y_2024` y `y_2025` con la definicion de **informalidad** que le fue asignada. Finalmente, para poder extender los resultados de Maurizio & Monsalvo (2021), cree la matriz `ocupados_X_2025_MM` utilizando una **union por intersección** (inner join) para sumar la columna con el vector `y_2024`. La idea es usar el estatus de informalidad para la misma persona el año anterior, por lo que es sumamente importante usar CODUSO, N_HOGAR y COMPONENTE en dicha union de bases de datos. No se preocupe si le quedan menos observaciones ya que, en principio, un 50% de los individuos entrevistados en 2024 T4 debería estar en 2025 T4 (pero siempre individuos de la muestra se caen. Luego de hacer dicha base final, pueden eliminar las columnas de identificación CODUSO, N_HOGAR y COMPONENTE ya que no son características relevantes para predecir informalidad en la siguiente parte.
2. Cree una tabla de la diferencia de medias `ocupados_X_2024` y `ocupados_X_2025` con las características seleccionadas en su matriz X.² Comente la tabla. ¿Hay diferencias estadísticas significativas entre las medias de sus características de cada año?

B. Modelo de Regresión Logística: Extensión el trabajo de Maurizio & Monsalvo (2021)

1. Estimación y Efectos Marginales: Estimen dos modelos de **Regresión Logística** usando `ocupados_X_2024` y `ocupados_X_2025_MM` para predecir la probabilidad de informal `y_2024` y `y_2025`, respectivamente. Esto es, el segundo modelo que usa `ocupados_X_2025_MM` sigue la especificación de Maurizio & Monsalvo (2021). Exporten una tabla de ambos modelos con: (i) los coeficientes estimados para cada variable característica de su matriz X, (ii) los errores estándar y (iii) los odd-ratios. Interpreten los resultados de la tabla. ¿Cambian mucho los coeficientes de características como *edad* o *educ* al introducir la información del estatus de informalidad? (*Hint*: en la clase de clasificación hay una ilustración de la ideal a presentar tabla).
2. Visualización: Tomando los datos de testeo `ocupados_X_2025_MM` y coeficientes estimados de 2024 en el item anterior, grafiquen la probabilidad de ser informal en 2025 contra alguna característica, formalmente: $\hat{P}(Y_{25} = 1 | \text{ocupados_X_2025_MM})$ en el eje vertical y alguna característica **numérica** (en el eje horizontal). Comente dicho gráfico y la variable seleccionada para ilustrar la probabilidad *acumulada* de ser

¹ Aclaración1: Por ejemplo, si pone la variable años de *educ* creada en el TP3, no ponga las dummies creadas de niveles educativos, ya que una esta en función de la otra.

² La tabla debería estar formateada como si fuese una “Balance Table Train vs Test Sample”.

informal según la característica seleccionada. (*Hint*: en las slides de clase hay una ilustración de este estilo que se espera en este ítem en el tema de logit).

C. Desempeño del modelo y predicción afuera de la muestra

1. Para **ambos modelos**, muestren la **matriz de confusión** (con umbral $p > 0.5$) comparando la predicción de $\hat{Y}_{25}$ con el vector observado y_{2025} , la **curva ROC** del modelo logit, y dos métricas más vistas en clase e interpreten los resultados.
2. Suponga que la Secretaría de Trabajo está interesada en identificar a grupos de trabajadores precarizados para dirigir los recursos de un programa de formalización laboral. Discutan cuál modelo de clasificación es “mejor” para predecir informales y asignar dichos recursos escasos. (*Hint*: recuerden que en la clase magistral discutimos el trade-off de minimizar error tipo I o II)

D. Herramientas de IA y reflexión final.

Se solicita detallar el uso de herramientas de Inteligencia Artificial en el TP, describiendo las tareas realizadas con ellas y evaluando su aporte al trabajo.

1. Reflexión (máximo 1 párrafo): Comenten cómo les ayudó la IA a programar: ¿en qué ítems fue más útil y en cuáles les resultó más difícil o menos efectiva? ¿Los ayudó en la interpretación?
2. Incluyan un Apéndice con todos los prompts de IA utilizados a lo largo del TP, copiados textualmente y en el orden en que fueron usados, y el nombre de la LLM utilizado (ChatGPT, Claude, Gemini, etc.) .
3. Por último, reporten aproximadamente el **tiempo total (en horas)** dedicado a la realización de este trabajo práctico.

Referencias

Maurizio, Roxana; Monsalvo, Ana Paula (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America*, WIDER Working Paper, No. 2021/19, ISBN 978-92-9256-953-2, The United Nations University World Institute for Development Economics. Research (UNU-WIDER), Helsinki, <https://doi.org/10.35188/UNU-WIDER/2021/953-2>