

Universidad de Buenos Aires

Facultad de Ciencias Económicas

Escuela de Negocios y Administración Pública

MAESTRÍA EN ECONOMÍA APLICADA

TALLER DE PROGRAMACIÓN

Tercer trabajo práctico – Grupo 3

INTEGRANTES:

LUCIANO ALTAMIRANO

GONZALO PASICHE

GITHUB:

[HTTPS://GITHUB.COM/LUCIANOALTAMIRANO435-RGB/GRUPO_3_TRABAJOS_PRACTICOS.GIT](https://github.com/LUCIANOALTAMIRANO435-RGB/GRUPO_3_TRABAJOS_PRACTICOS.GIT)

PROFESORA:

MARÍA NOELIA ROMERO

AGOSTO - 2026

1. Enfoque de validación y análisis descriptivo

Se definió la base de ocupados en dos submuestras anuales: una de ellas, correspondiente al cuarto trimestre del año 2024, se consideró la muestra de entrenamiento y otra submuestra, extraída del cuarto trimestre del año 2025, se tomó como la muestra de testeo. A partir de las conclusiones de Maurizio y Monsalvo (2021), se construyó una tercera base mediante la unión por intersección de ambas submuestras, y también se identificaron a los individuos entrevistados en dichos períodos mediante códigos de vivienda, hogar y componente; así, resultó posible incorporar el estado de informalidad del período anterior en una regresión adicional. Se presentaron, además, los resultados en una tabla de diferencias entre medias de las características elegidas en las muestras de entrenamiento y de testeo, contrastándolas mediante la prueba t de Student. En la tabla 1 se presentan los resultados del contraste mencionado, que evidencian la estructura y la dinámica intertemporal del perfil socioeconómico de los trabajadores en Argentina.

Tabla 1

Contrastes de diferencia de medias entre los registros de 2024 y 2025

Variable	Media de 2024	Media 2025	Diferencia	Estadístico t	Valor p
Recibo de la totalidad del sueldo	0,45	0,43	-0,01	-2,78	0,01
Cantidad de ocupaciones adicionales	0,23	0,24	0,01	0,97	0,33
Obrero o empleado	0,72	0,71	-0,02	-3,54	0,00
Patrón	0,04	0,04	0,00	0,42	0,67
No tiene cobertura médica	0,29	0,30	0,01	2,30	0,02
El trabajador emite factura	0,03	0,03	0,00	0,29	0,77
No recibe ni entrega ningún comprobante	0,21	0,21	0,00	0,13	0,89
Recibe un papel sin membrete ni firma del empleador	0,02	0,02	0,00	-1,49	0,14
Recibe un recibo con sello y firma del empleador	0,46	0,45	-0,01	-2,93	0,00
Presencia de menores de 5 años en el hogar	0,17	0,16	-0,01	-2,60	0,01
Edad	41,31	41,86	0,55	4,23	0,00
Edad_sq	1878,64	1928,69	50,04	4,33	0,00
Años de escolaridad	12,03	11,97	-0,06	-1,74	0,08
Se encuentra sin pareja	0,46	0,47	0,00	0,23	0,82
Horas de trabajo semanales de otras actividades	1,44	1,59	0,15	2,85	0,00
Horas de trabajo semanales de la actividad principal	35,86	35,91	0,05	0,29	0,77
Horas de trabajo semanales	38,81	39,09	0,28	1,17	0,24
Ingresos totales (log)	13,19	13,58	0,40	43,39	0,00
Integrantes del hogar	3,59	3,59	0,00	-0,08	0,94
Parte del sueldo fuera del recibo	0,01	0,01	0,00	0,27	0,79
Gran Buenos Aires	0,18	0,17	-0,01	-1,46	0,14
Noreste	0,10	0,09	-0,01	-2,25	0,02
Noroeste	0,21	0,22	0,01	1,37	0,17
Pampeana	0,30	0,31	0,02	3,44	0,00
Patagonia	0,12	0,11	-0,01	-2,49	0,01
Masculino	0,55	0,55	0,00	-0,99	0,32

Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del Instituto Nacional de Estadística y Censos (INDEC, 2026).

De las veintisiete características analizadas en la comparación entre las muestras de 2024 y 2025, doce han mostrado diferencias estadísticamente significativas al 5%. Las diferencias descritas en las características más relevantes corresponden a variables continuas: la edad media de los ocupados es superior entre ambas muestras, diferencia significativamente elevada en el estadístico t y seguida de un valor p significativo al 1%, al igual que ingresos totales presentan las diferencias más altas de toda la tabla, con un valor p significativo al 1%, lo que sugiere que el poder adquisitivo medio de los ocupados también creció entre trimestres y no sólo en función del cambio en la composición demográfica.

En relación con los parámetros cualitativos, hay diferencias significativas en la proporción de obreros o empleados, que disminuye ligeramente en 2025, y en la ausencia de cobertura médica, cuya presencia se incrementó levemente. La región pampeana muestra resultados significativos y aumenta su representación en 2025, mientras que las regiones Noreste y Patagonia experimentan leves descensos. Variables como el sexo, el estado civil, los años de escolaridad, las horas de trabajo en la actividad principal y la estructura familiar (integrantes del hogar) no presentan diferencias significativas, lo que indica que ambas muestras son comparables en sus características estructurales más importantes para predecir la informalidad.

2. Modelo de regresión logística

De esta forma se plantean los siguientes modelos, los cuales responden a interrogantes diferentes y utilizan herramientas distintas pero que pueden ser complementarias:

- Modelo 1: ¿Qué tipo de persona es informal? Responde con atributos o características como: edad, educación, región en donde vive, entre otras.
- El Modelo 2: parte de una situación del año pasado. ¿Dónde se encuentra el trabajador en este momento? Y la respuesta es que el pasado pesa muchísimo.

Y trata del esquema metodológico del modelo 2, que incluye el aporte de Maurizio & Monsalvo. Si la informalidad fuera un estado transitorio, la gente entraría y saldría; el estatus previo no debería predecir tanto. Que lo prediga con esa fuerza indica que es persistente: quien está en la informalidad tiende a quedarse ahí. Por eso se habla de trampa y no de etapa.

En ese sentido, la Tabla 2 muestra los resultados de los modelos de regresión logística estimados, siendo el primero el que predice la probabilidad de ser informal en 2024 a partir de las características personales y laborales de los ocupados en 2021, que funciona como muestra de entrenamiento, el segundo repite la especificación de Maurizio y Monsalvo (2021) pero, además de las características mencionadas, considera el estatus de informalidad de la periodicidad anterior como regresor adicional, estimado únicamente sobre la submuestra de individuos entrevistados en ambos períodos. Para cada modelo se presentan los coeficientes estimados, los errores estándar, los odds ratios y los efectos marginales promedio que permiten cuantificar el impacto de cada una de las características sobre la predicción de la probabilidad de informalidad.

Tabla 2

Estadísticos de los modelos de regresión logística explicativos de la informalidad en Argentina

Variable	Modelo 1 (2024)						Modelo 2 (2025 MM)							
	Coefficiente	Error estandar	Valor p	Sign.	Odds-ratio	EMP	Coefficiente	Error estandar	Valor p	Sign.	Odds-ratio	EMP	EMP std. error	
Cantidad de ocupaciones adicionales	0,156	0,0612	0,0108	**	1,1689	0,0129	0,0051	0,3072	0,1225	0,0121	**	1,3597	0,0185	0,0074
No tiene cobertura médica	1,6402	0,0898	0,0000	***	5,1563	0,1356	0,0071	1,4044	0,1755	0,0000	***	4,0731	0,0844	0,0104
Presencia de menores de 5 años en el hogar	0,0676	0,1095	0,5372		1,0699	0,0056	0,0091	-0,2597	0,2137	0,2242		0,7713	-0,0156	0,0128
Edad	-1,2422	0,2448	0,0000	***	0,2888	-0,1027	0,0202	-1,5524	0,4871	0,0014	***	0,2117	-0,0932	0,0293
Edad_sq	1,2134	0,2488	0,0000	***	3,365	0,1003	0,0205	1,4991	0,4792	0,0018	***	4,4776	0,09	0,0288
Años de escolaridad	-0,3652	0,0444	0,0000	***	0,6941	-0,0302	0,0037	-0,1728	0,0858	0,0440	**	0,8413	-0,0104	0,0052
Se encuentra sin pareja	0,3145	0,0896	0,0004	***	1,3696	0,026	0,0074	0,453	0,1756	0,0099	***	1,5731	0,0272	0,0105
Horas de trabajo semanales de otras actividades	0,0232	0,0676	0,7317		1,0234	0,0019	0,0056	-0,2734	0,1505	0,0692	*	0,7608	-0,0164	0,009
Horas de trabajo semanales de la actividad principal	-0,1059	0,0411	0,0100	***	0,8995	-0,0088	0,0034	-0,2356	0,0819	0,0040	***	0,7901	-0,0142	0,0049
Condición de informal en 2024	-	-	-	-	-	-	-	2,5849	0,1613	0,0000	***	13,2616	0,1553	0,0081
Ingresos totales (log)	-0,4028	0,0467	0,0000	***	0,6685	-0,0333	0,0038	-0,1211	0,0995	0,2233		0,8859	-0,0073	0,006
Integrantes del hogar	0,071	0,0438	0,1052		1,0736	0,0059	0,0036	0,0499	0,0877	0,5696		1,0512	0,003	0,0053
Gran Buenos Aires	0,0005	0,1591	0,9976		1,0005	0	0,0132	-0,0594	0,3132	0,8496		0,9423	-0,0036	0,0188
Noreste	-0,0046	0,1711	0,9784		0,9954	-0,0004	0,0141	-0,5927	0,3692	1,0184		0,5528	-0,0356	0,0222
Noroeste	0,026	0,1438	0,8567		1,0263	0,0021	0,0119	-0,2452	0,2599	0,3454		0,7825	-0,0147	0,0156
Pampeana	0,1804	0,1399	0,1970		1,1977	0,0149	0,0116	0,0074	0,2496	0,9764		1,0074	0,0004	0,015
Patagonia	0,0113	0,17	0,9472		1,0113	0,0009	0,0141	-0,4175	0,3297	0,2055		0,6587	-0,0251	0,0198
Masculino	-0,8763	0,088	0,0000	***	0,4163	-0,0725	0,0072	-0,5436	0,175	0,0019	***	0,5807	-0,0326	0,0105

Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del Instituto Nacional de Estadística y Censos (INDEC, 2026).

La comparación de los dos modelos de regresión planteados pone de relieve una diferencia considerable en los coeficientes al introducir la condición previa de informalidad. De todas las covariables, la edad es la que presenta el mayor cambio en su estimador en el modelo 1, puesto que el coeficiente es negativo y altamente significativo, lo que indica que los trabajadores de mayor edad tienen menos probabilidades de ser informales; sin embargo, al pasar al modelo 2, el coeficiente se vuelve aún más negativo, aunque el alto nivel de significación estadística se mantiene. Complementariamente, el término cuadrático de la edad sigue siendo positivo y significativo, tanto para el modelo 1 como para el modelo 2, de manera que la relación no lineal entre la edad y la informalidad persiste aun manteniendo constante el estatus previo de informalidad.

La variable correspondiente a los años de escolarización también constituye un claro ejemplo de un cambio sustancial al incorporarse el estatus de informalidad del año anterior. En el modelo 1, el coeficiente obtenido era negativo y ligeramente significativo, en consonancia con la evidencia de que una mayor educación disminuye la probabilidad de informalidad. En el modelo 2, ese coeficiente se reduce y se vuelve significativo sólo al 5%, por lo que se puede concluir que una parte del efecto de la educación operaba en el modelo 1 capturando indirectamente la persistencia en la informalidad. Dicho de otra forma, si los trabajadores con mayor educación tienen menor probabilidad de ser informales, también tienen menor probabilidad de cambiar su condición de un periodo a otro.

El sexo masculino es una de las diferencias más evidentes entre los modelos analizados, puesto que en el modelo 1 la estimación es negativa y extremadamente significativa, lo que implica que los varones presentan un menor riesgo de informalidad que las mujeres. Esta condición se mantiene en el modelo 2, aunque de menor magnitud, y sigue siendo significativa. Algo similar ocurre en la


relación con el estado civil, donde la condición de estar sin pareja presenta un estimador positivo y significativo en ambos modelos, aunque en el modelo 2 la magnitud del efecto aumenta ligeramente, lo que sugiere que esta característica también captura, en parte, efectos de persistencia.

El aspecto más relevante del modelo 2 es el coeficiente asociado a la condición de informal en el año 2024, que presenta un signo positivo, un tamaño grande y es altamente significativo, convirtiéndose en el predictor más fuerte de la regresión analizada. Su odd ratio indica que haber sido informal el año previo aumenta considerablemente las probabilidades de continuar siéndolo en 2025, independientemente de las demás características individuales observables. El hallazgo es consistente con la evidencia de Maurizio y Monsalvo (2021) para Argentina y otros países latinoamericanos, quienes encuentran una clara persistencia del estatus de informalidad más allá de las características del trabajador.

En lo que respecta a la variable de ingresos totales, incorporando el logaritmo, también refuerza la interpretación anterior, ya que en el modelo 1 tiene un coeficiente negativo y muy significativo, por lo cual una mayor cantidad de estos se relaciona con una menor probabilidad de informalidad, lo cual era la expectativa lógica, dado que un trabajo formal suele traer aparejados mayores ingresos. En contraste, en el modelo 2, ese coeficiente ya no es estadísticamente significativo y su valor disminuye notablemente. Esto indica que gran parte de la relación entre ingresos e informalidad observada en 2024 se debe a la persistencia del estado informal, puesto que al controlar el estatus previo, el ingreso deja de ser un predictor independiente relevante de la situación laboral en 2025.

Figura 1

Probabilidad predicha de ser informal en 2025 según edad (evaluada en modelo 1 y modelo 2)



Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del Instituto Nacional de Estadística y Censos (INDEC, 2026).


El Gráfico 1 resulta particularmente ilustrativo: se observa que la probabilidad estimada de informalidad describe una U a lo largo del ciclo de vida, con un mínimo en torno a los 48 años. El patrón responde a la lógica de las trayectorias laborales: el ingreso al mercado de trabajo ocurre mayoritariamente por la vía no registrada, la registración se consolida en las edades centrales y la precariedad reaparece hacia el final de la vida activa, cuando la reinserción formal se vuelve difícil y crece el peso del trabajo autogestionado de subsistencia. La curva predicha se ajusta de cerca a la tasa efectivamente observada en 2025, lo que confirma que la estructura estimada con datos de 2024 mantiene su validez al año siguiente.

En el aporte del segundo panel del Gráfico 1 se muestra la distancia entre las curvas. A la misma edad y con las mismas características, quien era informal en 2024 enfrenta una probabilidad de reincidencia muy superior a la de un trabajador formal: el estatus rezagado tiene un odds ratio de 13.3, y la brecha se mantiene en todo el rango etario. La informalidad opera así menos como una etapa transitoria que como una condición que se reproduce a sí misma. Estos hallazgos se alinean con lo expresado por Maurizio y Monsalvo (2021), quienes abordaron la persistencia de esta condición. Así, lo que en el Modelo 1 se atribuía a las características

individuales era, en buena medida, inercia de la situación anterior. Un aspecto metodológico a tener en cuenta es que por encima de los 70 años la curva se apoya en pocas observaciones, de modo que el repunte final debe leerse con reservas

Figura 2

Matrices de confusión y curva ROC de los modelos de regresión logística analizados



Nota. Elaboración propia con base en la Encuesta Permanente de Hogares del Instituto Nacional de Estadística y Censos (INDEC, 2026).

Si bien las matrices de confusión arrojan resultados muy buenos (89.7% y 92% respectivamente), es necesario tomarlos con cautela, ya que podrían resultar engañosas: con una tasa de informalidad del 10.8%, clasificar a todos como formales acertaría en el 89.2% de las veces. El Modelo 1 apenas mejora esa referencia. El problema se ve al descomponer los errores: de 319 informales observados, el Modelo 1 detecta 45 y el Modelo 2, 154, con sensibilidades del 14,1% y del 48,3%, respectivamente. Ambos son muy conservadores al señalar la informalidad, lo que explica sus altas especificidades y escasos falsos positivos (31 y 73, respectivamente). Siendo esto, un problema de trabajar con clases desbalanceadas, en donde la exactitud dice poco y la sensibilidad dice casi todo.

Por otro lado, las curvas ROC corrigen ese diagnóstico. Con áreas de 0,836 y 0,892, ambos modelos clasifican bien a los individuos según su riesgo de informalidad, muy por encima de un clasificador aleatorio. La tensión entre un AUC alto y una sensibilidad baja no revela un problema de capacidad predictiva, sino de punto de corte: el umbral de 0,5 minimiza el error total, objetivo que, con clases desbalanceadas, se alcanza al desatender a la clase minoritaria. El Modelo 2 domina en casi todo el recorrido, si bien sus métricas se calculan sobre la muestra con la que fue estimado y, por ello, están sobrevaluadas, mientras que el Modelo 1 se evalúa genuinamente fuera de muestra.

Finalmente, si se tuviera que brindar una recomendación técnica y basándonos en el trade-off de errores tipo 1 y tipo 2 hay que tener en cuenta que ambos errores tienen costos asimétricos. Incluir a un trabajador formal supone un gasto mal dirigido; excluir a uno informal supone que la política no alcanza a su destinatario, con costos que se prolongan en la falta de cobertura previsional y de salud. Si el objetivo es formalizar, el error de tipo II es el más costoso y el criterio de selección debe privilegiar la cobertura sobre la precisión.

El umbral de 0.5 es inadecuado para ese fin: deja fuera al 86% de los informales según el Modelo 1 y al 52% según el Modelo 2, con una filtración mínima de formales. Hay un amplio margen para reducirlo y ganar cobertura a bajo costo. La restricción presupuestaria, sin embargo, acota ese razonamiento: cuando los fondos alcanzan para un número limitado de beneficiarios, cada formal incorporado desplaza a un informal, y la precisión recupera peso. El umbral óptimo se ubica en el punto en el que el costo de sumar un falso positivo iguala al beneficio de alcanzar a un informal adicional.

Entre los modelos, el Modelo 2 es superior en todos los indicadores, pero su uso exige observar al individuo durante dos años consecutivos, condición que aquí cumple apenas el 37% de los ocupados. Por ello, se recomienda un esquema mixto: aplicar el

Modelo 2 cuando exista historia laboral previa, registros de seguridad social o paneles de encuesta, y el Modelo 1 como herramienta universal para el resto, en ambos casos con umbrales inferiores a 0.5. La persistencia estimada sugiere además planteamiento de política: si el estatus informal se reproduce con esta fuerza, es persistente de acuerdo Maurizio y Monsalvo (2021), intervenir temprano resulta necesario, antes de que la trayectoria se consolide, y además es más eficiente que intentar revertirla después

3. Herramientas de la IA y reflexión final

Por una parte, se valora la contribución de la inteligencia artificial como herramienta de aprendizaje y programación, remarcando su utilidad para acceder rápidamente a la base de datos y, al mismo tiempo, para generar código que se interprete con claridad en Python, aunque se considera que el apoyo fue menos relevante en la fase interpretativa. A continuación, un registro de *prompts* que se van utilizando a lo largo del desarrollo y que se refiere a un apéndice. Finalmente, se valora el tiempo total dedicado a este trabajo, teniendo en cuenta las dificultades de entrega, que se asocian principalmente a un aprendizaje lento al adaptarse a nuevas herramientas de trabajo colaborativo y a conceptos que anteriormente no se habían visto.

Pese a la utilidad que representa la IA, al tratarse del tercer trabajo práctico, el proceso ha demandado un tiempo considerable, debido al aprendizaje de su funcionamiento y a los otros costos de transacción propios del trabajo virtual, que, afortunadamente, han disminuido. Además, ha permitido la adecuación a nuevos conceptos, como los clústeres jerárquicos y las k-modas, que resultaron retadores. En conjunto, esto ha supuesto una dedicación de aproximadamente 15 horas. Se espera que este tiempo se reduzca en los próximos entregables, considerando, además, el escaso margen temporal entre ellos según el cronograma y la existencia de otras responsabilidades que deben atenderse en paralelo.

4. Referencias

Instituto Nacional de Estadística y Censos. (2026). *Bases de datos*. <https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos>

Maurizio, R., y Monsalvo, A. P. (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America* (Vol. 2021). United Nations. <https://doi.org/10.35188/UNU-WIDER/2021/953-2>

1. Anexos y apéndices

Anexo 1

Resumen descriptivo de las variables contempladas en los modelos de regresión Logit

Nombre original (EPH)	Nombre final en la base	Modelo 1 (2024)	Modelo 2 (2025 MM)	Motivo de exclusión
PP03D	cant_ocupaciones_ad	Si	Si	-
CH08	cobertura_med_No cobertura	Si	Si	-
(creada en el TP1, sin nombre original)	dummy_menor5	Si	Si	-
CH06	edad	Si	Si	-
(creada en el TP2, sin nombre original)	edad2	Si	Si	-
CH12 + CH13 + CH14 (combinadas)	educ	Si	Si	-
CH07	estado_civil_Sin pareja	Si	Si	-
PP3F_TOT	horas_s_otras_act	Si	Si	-
PP3E_TOT	horas_s_principal	Si	Si	-
P47T	ingreso_total (log)	Si	Si	-
(creada en el TP2, sin nombre original)	nhogar	Si	Si	-
REGION (etiquetada)	region_cat_Gran Buenos Aires	Si	Si	-
REGION (etiquetada)	region_cat_Noreste	Si	Si	-
REGION (etiquetada)	region_cat_Noroeste	Si	Si	-
REGION (etiquetada)	region_cat_Pampeana	Si	Si	-
REGION (etiquetada)	region_cat_Patagonia	Si	Si	-
CH04	sexo_Masculino	Si	Si	-
(creada en el TP3 via 'join' con 2024, sin nombre original)	informal_2024_Informal	-	Si	No existe para 2024 (es el estatus del año anterior); regresor adicional de Maurizio & Monsalvo (2021) solo en el Modelo 2
CODUSU	cod_vivienda	No	No	Identificadora, usada solo para el 'join'
NRO_HOGAR	nro_hogar	No	No	Identificadora, usada solo para el 'join'
COMPONENTE	componente	No	No	Identificadora, usada solo para el 'join'
ANO4	ano	No	No	Identificadora (separa las bases por año)
TRIMESTRE	trimestre	No	No	Identificadora
(creada en el paso 0.3, sin nombre original)	año	No	No	Identificadora duplicada de 'ano'
(creada en el TP2, sin nombre original)	id	No	No	Identificadora, usada solo para el 'join'
PONDERA	ponderador	No	No	Factor de expansion muestral, no es una característica
ESTADO	cond_actividad	No	No	Constante entre ocupados (ESTADO = 1 para todos)
CH04	CH04 (cruda, sin encodear)	No	No	Redundante con la dummy sexo_Masculino (paso 1.6)
CH07	CH07 (cruda, sin encodear)	No	No	Redundante con la dummy estado_civil_Sin pareja (paso 1.6)
CH08	CH08 (cruda, sin encodear)	No	No	Redundante con la dummy cobertura_med_No cobertura (paso 1.6)
NIVEL_ED	nivel_ed (cruda)	No	No	Redundante con su version etiquetada nivel_ed_cat (paso 1.8)
CAT_OCUP	cat_ocup (cruda)	No	No	Redundante con su version etiquetada cat_ocup_cat (paso 1.8)
EMPLEO	tipo_empleo (cruda)	No	No	Redundante con su version etiquetada tipo_empleo_cat (paso 1.8)

Nombre original (EPH)	Nombre final en la base	Modelo 1 (2024)	Modelo 2 (2025 MM)	Motivo de exclusión
SECTOR	tipo_sector (cruda)	No	No	Redundante con su version etiquetada tipo_sector_cat (paso 1.8)
REGION	region (cruda)	No	No	Redundante con su version etiquetada region_cat (paso 1.8)
PP07K	comprobante_sal (cruda)	No	No	Redundante con su version etiquetada comprobante_sal_cat (paso 1.8)
PP07L	alcance_recibo (cruda)	No	No	Redundante con su version etiquetada alcance_recibo_cat (paso 1.8)
PP07M	parte_sueldo (cruda)	No	No	Redundante con su version etiquetada parte_sueldo_cat (paso 1.8)
PP07H	desc_jub_cod (cruda)	No	No	Redundante con la dummy desc_jubilatorio (paso 1.6)
PP04C99	tam_estab_cod (cruda)	No	No	Redundante con la dummy tam_estab_agrup (paso 1.6)
CAT_OCUP (recodificada)	cat_ocup2 (dummies)	No	No	Definitoria de 'informal' (insumo directo de la definicion, paso 1.9)
CAT_OCUP (etiquetada)	cat_ocup_cat (dummies)	No	No	Definitoria de 'informal'
PP07H (recodificada)	desc_jubilatorio (dummies)	No	No	Definitoria de 'informal' (insumo directo de la definicion, paso 1.9)
PP04C	tam_estab	No	No	Definitoria de 'informal' (insumo directo de la definicion, paso 1.9)
PP04C99 (etiquetada)	tam_estab_agrup (dummies)	No	No	Definitoria de 'informal'
SECTOR (recodificada)	sector_2 (dummies)	No	No	Definitoria de 'informal'
SECTOR (etiquetada)	tipo_sector_cat (dummies)	No	No	Definitoria de 'informal'
EMPLEO (etiquetada)	tipo_empleo_cat (dummies)	No	No	Definitoria de 'informal'
PP07K (etiquetada)	comprobante_sal_cat (dummies)	No	No	Definitoria de 'informal' (asociada al registro del pago)
PP07L (etiquetada)	alcance_recibo_cat (dummies)	No	No	Definitoria de 'informal' (asociada al registro del pago)
PP07M (etiquetada)	parte_sueldo_cat (dummies)	No	No	Definitoria de 'informal' (asociada al registro del pago)
CH03	parentesco (dummies)	No	No	Varianza cuasi-nula entre ocupados en la muestra de entrenamiento (2024)
NIVEL_ED (recodificada)	nivel_ed2_Superior	No	No	Representacion redundante de educacion (se conserva unicamente 'educ')
NIVEL_ED (etiquetada)	nivel_ed_cat (dummies)	No	No	Representacion redundante de educacion (se conserva unicamente 'educ')
CH12	nivel_ed_alto (dummies)	No	No	Representacion redundante de educacion (se conserva unicamente 'educ')
CH13	finalizacion_nivel_Si	No	No	Representacion redundante de educacion (se conserva unicamente 'educ')
CH14	nivel_ed_aprb (dummies)	No	No	Representacion redundante de educacion (se conserva unicamente 'educ')
P21	ingreso_ppal (log)	No	No	Colineal con ingreso_total; se conserva unicamente 'ingreso_total'
PP3E_TOT + PP3F_TOT (combinadas)	horastrab	No	No	Colineal con horas_s_principal + horas_s_otras_act, que se conservan por separado
(creada en el TP2, sin nombre original)	horastrabj	No	No	Colineal con horastrab / horas_s_principal + horas_s_otras_act
PP04D COD	cod_ocupacion	No	No	Alta cardinalidad, sin valor directo como regresora en el logit

Nota. Elaboración propia.

Apéndice 1: Prompts utilizados

Para el desarrollo del análisis propuesto, se consideraron los *prompts* que se presentan a continuación, lo cual supuso una ventaja analítica para realizar actividades repetitivas en menos tiempo, de modo que el abordaje analítico pudo centrar sus esfuerzos en la exploración cuantitativa de orden descriptivo e inferencial.

- Con la explicación que te di sobre la eliminación de determinadas variables, desarrolla una tabla resumen que muestre el nombre original de las variables, su nombre final en la base, si fueron consideradas en las especificaciones de los modelos de regresión logística y el motivo de su exclusión.
- Puedes revisar este código
- Dime si existe alguna inconsistencia
- Por que se considera que estas son variables tautológicas, estas otras variables también no lo serían?
- Perfecto entonces habría que eliminarlas y corregir el error en indexación
- Bien, mira este gráfico, analiza el estilo
- Necesito que con la variable de probabilidad estimada y la variable de edad realices dos gráficos uno para cada modelo 1 y 2
- Realiza un matriz de confusión para ambos modelos
- Realiza un gráfico de ROC en este gráfico deben estar ambos modelos
- Dame un código en que los 3 gráficos esten en la misma imagen, una al costado de otra